Journal of Advanced Computing and Digital Information Systems

e-ISSN: 1234-5678 | p-ISSN: 9012-3456

Volume 1, Nomor 1, Desember 2026, 1–9.
Doi: 10.xxxxx/jacdis/12345

Artikel Penelitian

Sistem Rekomendasi Destinasi Wisata Jawa Timur Berbasis Content-Based Filtering dan Filter Musim Menggunakan Representasi Semantik IndoBERT

Malik Hariyanto [1], Muhammad Rifqi Razzan Pratama [2] , Muhammad Iqbal Faza [3], Yahya Ahmad [4]

[1] Sistem Informasi, Universitas Trunodjoyo Madura, Bangkalan, Indonesia;

* Penulis korespondensi: 230441100067@student.trunojoyo.co.id ,230441100185@student.trunojoyo.co.id ,230441100124@student.trunojoyo.co.id ,230441100079@student.trunojoyo.co.id .

Riwayat artikel: Diterima 10 Januari 2026; Direvisi 10 Februari 2026; Disetujui 10 Maret 2026; Tersedia secara daring 20 Maret 2026.

© 2026 Penulis. Diterbitkan oleh Ateksa, Indonesia. Artikel ini dilisensikan di bawah *Creative Commons Attribution* (BY-NC) 4.0: https://creativecommons.org/licenses/by-nc/4.0.

Cara Mensitasi

Gaya Sitasi: **APA Edisi ke-6**

Malik Hariyanto., Muhammad Rifqi Razzan Pratama., Muhammad Iqbal Faza., & Yahya Ahmad (2026). sistem Rekomendasi Destinasi Wisata Jawa Timur Berbasis Content-Based Filtering dan Konteks Cuaca Menggunakan Representasi Semantic IndoBERT. *Journal of Advanced Computing and Digital Information Systems, 1*(1), 1–30. Doi: 10.xxxxx/jacdis/12345.

Abstrak

Pemeringkatan destinasi wisata berbasis ulasan perlu mempertimbangkan kesesuaian teks kueri dan konteks kunjungan. Penelitian ini membandingkan tiga konfigurasi pada 207 destinasi (79.504 ulasan setelah prapemrosesan): C1 (IndoBERT dengan rating Bayesian), C2 (TF-IDF dengan rating Bayesian), dan C3 (fusi skor IndoBERT dan TF-IDF dengan rating Bayesian). Ketiganya memakai filter musim dan kategori yang sama. Evaluasi menggunakan 60 kueri dalam empat skenario dan 1.467 pasangan kueri–destinasi yang dinilai otomatis pada skala 0–3. Dengan hanya label 3 sebagai relevan, Recall@10 C1, C2, dan C3 masing-masing 0,5277, 0,5266, dan 0,5266; MRR@10 sebesar 1,0000, 0,9917, dan 0,9917; NDCG@10 sebesar 0,9994, 0,9961, dan 0,9962. Fusi tidak meningkatkan relevansi dibanding IndoBERT. Seluruh perbedaan antarkonfigurasi berasal dari satu kueri dan 99,80% pasangan berlabel 3, sehingga evaluasi belum mampu membedakan kualitas konfigurasi. Temuan ini menunjukkan perlunya penilaian relevansi yang lebih sulit dan divalidasi manusia sebelum keunggulan suatu metode dapat diuji.

Kata kunci: rekomendasi wisata; pemeringkatan berbasis konten; IndoBERT; TF-IDF; fusi skor; rating Bayesian; konteks musim; evaluasi relevansi.

Abstract

Ranking tourist destinations from reviews requires matching both the text of a query and the visit context. This study compares three configurations on 207 destinations (79,504 reviews after preprocessing): C1 (IndoBERT with Bayesian rating), C2 (TF-IDF with Bayesian rating), and C3 (score fusion of IndoBERT and TF-IDF with Bayesian rating). All three use the same season and category filters. Evaluation uses 60 queries in four scenarios and 1,467 query–destination pairs judged automatically on a 0–3 scale. With only grade 3 counted as relevant, Recall@10 for C1, C2, and C3 is 0.5277, 0.5266, and 0.5266; MRR@10 is 1.0000, 0.9917, and 0.9917; and NDCG@10 is 0.9994, 0.9961, and 0.9962. Fusion does not improve relevance over IndoBERT. All differences between configurations come from a single query, and 99.80% of pairs receive grade 3, so the evaluation cannot yet separate the configurations. The results show that harder, human-validated relevance judgments are needed before the superiority of any method can be tested.

***Keywords**: tourism recommendation; content-based ranking; IndoBERT; TF-IDF; score fusion; Bayesian rating; seasonal context; relevance evaluation.*

1. Pendahuluan

Sistem rekomendasi wisata berkembang dari pendekatan berbasis rating dan kemiripan konten menjadi sistem hibrida yang menggabungkan banyak sinyal. Chalkiadakis et al. (2023) memadukan elisitasi preferensi Bayesian dengan komponen berbasis konten, sedangkan Huda et al. (2024) menggabungkan *collaborative filtering*, demografi, analisis sentimen berbasis aspek, dan *content-boosted filtering*. Rating agregat juga dipakai langsung sebagai kriteria rekomendasi, misalnya pada wisata halal Indonesia (Arif et al., 2022).

Selain rating, konteks kunjungan memengaruhi kandidat yang layak direkomendasikan. Yoon dan Choi (2023) memanfaatkan temperatur dan presipitasi, dan Banerjee et al. (2025) memasukkan permintaan musiman dan bulan perjalanan. Pada penelitian ini konteks berupa label musim statis dan kategori wisata per destinasi, bukan data cuaca waktu nyata.

Untuk kecocokan antara kueri dan isi ulasan, dua representasi teks lazim digunakan. TF-IDF mencocokkan istilah kueri dengan kosakata ulasan (Salton & Buckley, 1988). IndoBERT (Wilie et al., 2020), yang berbasis BERT (Devlin et al., 2019), menghasilkan representasi kontekstual bahasa Indonesia. Kedua skor dapat digabungkan pada tingkat skor. Namun, ketika rating dan filter konteks dibuat sama, manfaat fusi dibanding masing-masing representasi belum jelas. Pertanyaan ini juga bergantung pada kualitas evaluasi. Penilaian relevansi otomatis oleh LLM memungkinkan evaluasi berskala besar, tetapi rentan terhadap bias dan menuntut validasi terhadap penilai manusia (Zheng et al., 2023; Nadăş, 2026).

Penelitian ini membandingkan tiga konfigurasi pada 207 destinasi wisata Jawa Timur: IndoBERT, TF-IDF, dan fusi keduanya. Semuanya memakai rating Bayesian dan filter musim serta kategori yang sama. Sistem bersifat *content-based* karena destinasi diperingkat dari isi ulasannya. Masukan berupa kueri teks, tanpa profil pengguna. Pertanyaan penelitiannya:

- **RQ1.** Bagaimana kinerja ketiga konfigurasi pada 60 kueri ketika relevansi biner didefinisikan secara ketat (label 3) dan longgar (label ≥ 2)?
- **RQ2.** Apakah fusi IndoBERT–TF-IDF meningkatkan relevansi dibanding masing-masing representasi?

- **RQ3.** Seberapa kuat penilaian relevansi otomatis membedakan kualitas ketiga konfigurasi?

Kontribusi penelitian ini adalah (1) perbandingan terkendali tiga konfigurasi dengan kandidat, rating, dan filter yang sama; (2) analisis sensitivitas terhadap definisi relevansi; dan (3) analisis daya pembeda evaluasi, mencakup kejenuhan label, pengaruh ukuran *pool* pada Recall, dan sirkularitas antara filter dan rubrik. Bagian 2 meninjau literatur, Bagian 3 menguraikan metode, Bagian 4 menyajikan hasil, Bagian 5 membahas temuan dan keterbatasan, dan Bagian 6 menyimpulkan.

2. Tinjauan Pustaka

2.1. Rekomendasi Wisata Hibrida dan Sinyal Konteks

Sistem rekomendasi wisata memakai beragam sinyal. Chalkiadakis et al. (2023) menggabungkan elisitasi preferensi Bayesian dengan komponen berbasis konten. Huda et al. (2024) memadukan *collaborative filtering*, demografi, analisis sentimen berbasis aspek, dan *content-boosted filtering*, sedangkan SABTR menghubungkan pengguna dan destinasi melalui LDA (Li et al., 2024). Pada wisata halal Indonesia, delapan kriteria rating dipakai untuk merekomendasikan destinasi (Arif et al., 2022), dan model pilihan (*choice models*) mempelajari preferensi dari pilihan pengguna untuk dibandingkan dengan pendekatan berbasis rating (Almomani et al., 2022). Untuk konteks, R2Tour memanfaatkan temperatur dan presipitasi (Yoon & Choi, 2023), sementara rekomendasi perjalanan kota memasukkan permintaan musiman dan bulan perjalanan (Banerjee et al., 2025).

Studi-studi tersebut memakai banyak komponen sekaligus sehingga sumbangan masing-masing sinyal sulit dipisahkan. Penelitian ini memegang rating dan filter tetap, lalu hanya mengubah sinyal teks.

2.2. Representasi Leksikal, Kontekstual, dan Fusi Skor

TF-IDF merepresentasikan teks berdasarkan frekuensi istilah (Salton & Buckley, 1988). BERT menghasilkan representasi kontekstual melalui pelatihan dua arah (Devlin et al., 2019), dan IndoBERT dari IndoNLU menyediakan varian untuk bahasa Indonesia (Wilie et al., 2020). Rata-rata keluaran token BERT tanpa penyetelan terbukti kurang optimal untuk kemiripan kalimat dibanding model yang dilatih khusus untuk tujuan itu (Reimers & Gurevych, 2019), sehingga pilihan IndoBERT tanpa *fine-tuning* pada penelitian ini perlu dibaca sebagai konfigurasi dasar. Untuk penggabungan sinyal, *reciprocal rank fusion* menggabungkan peringkat dari beberapa sistem (Cormack et al., 2009); penelitian ini memakai fusi pada tingkat skor. Pendekatan semantik juga diteliti pada domain video (Sharma et al., 2021), tetapi hasilnya tidak dapat dipindahkan begitu saja ke destinasi wisata.

2.3. Evaluasi: Metrik, *Pooling*, dan Penilai LLM

NDCG memakai gain bertingkat dengan diskon logaritmik (Järvelin & Kekäläinen, 2002), dan MRR mengukur peringkat objek relevan pertama (Craswell, 2009). Evaluasi berbasis *pool* menilai hanya kandidat yang dikembalikan sistem peserta, sehingga hasilnya dapat condong ke sistem pembentuk *pool* (Zobel, 1998). Distribusi popularitas juga memengaruhi metrik evaluasi rekomendasi (Mena-Maldonado et al., 2021). Penilai berbasis LLM menawarkan skala besar, tetapi rentan terhadap bias posisi, panjang, dan preferensi terhadap keluaran model sendiri, serta menuntut dokumentasi dan validasi terhadap penilai manusia (Zheng et al., 2023; Nadăş, 2026). Literatur evaluasi yang lebih luas mencakup keadilan bagi berbagai pemangku kepentingan wisata (Banerjee et al., 2023), simulasi kampanye promosi destinasi (Piliponyte et al., 2024), dan kerangka evaluasi yang mengaitkan rekomendasi dengan perilaku pengguna (Henriques & Pinto, 2023). Perencanaan rute personal

(Gamidullaeva et al., 2023) dan pustaka rekomendasi sadar konteks (Zheng, 2022) memberi konteks pengembangan sistem, tetapi berada di luar cakupan penelitian ini.
Celah yang dituju penelitian ini ialah perbandingan terkendali tiga konfigurasi pada koleksi ulasan wisata berbahasa Indonesia, disertai pemeriksaan seberapa jauh penilaian otomatis mampu membedakannya.

3. Metode Penelitian

3.1. Rancangan dan Data

Penelitian ini membandingkan tiga konfigurasi secara luring pada satu koleksi tetap. Destinasi adalah unit rekomendasi dan kueri adalah unit evaluasi. Dataset ulasan berisi 79.514 baris dan delapan kolom: `id_destinasi`, `destinasi`, `rating`, `date`, `text_original`, `text_preprocessed`, `rekomendasi_cuaca`, dan `wisata`. Setelah prapemrosesan tersisa 79.504 ulasan dari 207 destinasi dalam 14 kategori. Jumlah ulasan bersih per destinasi berkisar 7–1.331 (median 352), dan rating 5 menyumbang 71,38% baris awal (56.759 dari 79.514). Kolom `rekomendasi_cuaca` berisi label musim statis per destinasi: 113 destinasi berlabel *Kemarau & Penghujan* dan 94 berlabel *Kemarau*. Gambar 1 menunjukkan alur pemeringkatan dan evaluasi.

Ulasan dikumpulkan dari Google Maps untuk destinasi wisata di Jawa Timur. Dataset tidak memuat kolom nama pengulas. Kolom date menyimpan waktu relatif terhadap saat pengambilan data (misalnya “2 minggu lalu” atau “Diedit 4 hari lalu”), sehingga periode ulasan tidak dapat direkonstruksi dari data dan penelitian ini tidak menganalisis dimensi temporal. Label musim dan kategori pada kolom rekomendasi_cuaca dan wisata merupakan metadata destinasi yang menjadi dasar filter konteks.



Gambar 1. Alur pemeringkatan dan evaluasi. Evaluasi dihitung ulang dari peringkat tersimpan.

Tabel 1. Data dan komponen eksperimen.

Komponen	Karakteristik
Korpus awal	79.514 baris; 8 kolom; 207 destinasi
Korpus setelah prapemrosesan	79.504 ulasan; 207 destinasi; 14 kategori
Label musim per destinasi	Kemarau & Penghujan: 113; Kemarau: 94
Kueri uji	60 kueri; 4 skenario; masing-masing 15 kueri
Penilaian relevansi	1.467 pasangan unik kueri–destinasi; 203 destinasi terwakili
Peringkat yang dievaluasi	3 konfigurasi × 60 kueri × 3 nilai K = 540 baris hasil

Catatan: tidak tersedia riwayat interaksi pengguna individual.

3.2. Prapemrosesan

Baris tanpa ID destinasi, nama destinasi, atau teks ulasan dikeluarkan, sehingga 10 baris dengan teks kosong terbuang. Fungsi `light_clean_text` kemudian menerapkan lima langkah: (1) mengubah teks menjadi huruf kecil; (2) menghapus URL, *mention*, dan simbol *hashtag*; (3) menghapus rentang emoji tertentu; (4) menghapus karakter selain huruf Latin, angka, dan spasi; (5) merapikan spasi dan membuang teks kosong. Hasilnya menggantikan kolom `text_preprocessed` bawaan. Tidak ada *stemming*, penghapusan *stopword*, perbaikan encoding, maupun deduplikasi ulasan.

3.3. Representasi Destinasi

Encoder `indobenchmark/indobert-base-p1` dipakai tanpa *fine-tuning* dalam mode inferensi, dengan panjang maksimum 128 token, *batch size* 32, dan *seed* 42. Presisi FP16 dipakai pada *forward pass* ketika CUDA tersedia, dan hasil disimpan sebagai float32. Embedding ulasan dihitung dengan *masked mean pooling*, lalu profil destinasi adalah rata-rata embedding ulasannya (Persamaan 1).

$$e(r) = \frac{\sum_t a_t h_t}{\sum_t a_t}$$

$$v(d) = \frac{1}{|R(d)|} \sum_{r \in R(d)} e(r) \quad (1)$$

Pada Persamaan (1), h_t adalah vektor token ke-t, a_t adalah *attention mask*, e(r) adalah embedding ulasan r, R(d) adalah himpunan ulasan destinasi d, dan v(d) adalah profil destinasi. Matriks ulasan berukuran 79.504 × 768 dan matriks destinasi 207 × 768. Kueri dikodekan dengan model dan *pooling* yang sama, lalu dibandingkan dengan v(d) melalui *cosine similarity*.

Untuk TF-IDF, teks bersih tiap destinasi digabung menjadi satu dokumen dengan `max_features=20000`, `ngram_range=(1,2)`, `min_df=1`, dan `sublinear_tf=True`. Matriks yang terbentuk berukuran 207 × 20.000 dengan *sparsity* 0,8821. Kueri diteruskan langsung ke *tokenizer* IndoBERT dan transformasi TF-IDF tanpa fungsi `light_clean_text`; konsekuensinya dibahas pada Bagian 5.

3.4. Filter Konteks, Rating Bayesian, dan Fusi Skor

Konteks diambil dari kolom eksplisit pada berkas kueri, bukan dari ekstraksi otomatis teks. Filter Kemarau menerima label *Kemarau* dan *Kemarau & Penghujan*; filter Penghujan hanya menerima *Kemarau & Penghujan*. Kategori memakai pencocokan persis terhadap metadata. Bila kedua konteks diberikan, kandidat adalah irisannya; bila tidak ada konteks, filter dilewati. Tidak ada mekanisme

fallback untuk kasus tanpa kandidat. Label musim bukan data cuaca waktu nyata dan tidak menjamin keamanan kunjungan.

Rating Bayesian dihitung dengan Persamaan (2), dengan R̄(d) rata-rata rating destinasi, n(d) jumlah rating, C rata-rata global (4,5107 pada data bersih), dan m = 10 sebagai kekuatan prior. Parameter m bukan ambang pengeluaran: destinasi dengan ulasan kurang dari 10 tetap diproses. Rentang WR adalah 3,5346–4,8438.

$$WR(d) = \frac{n(d)}{n(d)+m} \cdot \overline{R}(d) + \frac{m}{n(d)+m} \cdot C \tag{2}$$

Semua skor dinormalisasi dengan min–max (Persamaan 3). WR dinormalisasi pada seluruh 207 destinasi sebagai B. Skor *cosine* IndoBERT (I) dan TF-IDF (T) dinormalisasi terpisah pada kandidat tiap kueri setelah filter; bila rentang skor mendekati nol menurut `np.isclose`, skor ternormalisasi diisi nol. Karena itu filter memengaruhi skala skor konten walaupun bobot fusi tetap.

$$\tilde{x} = \frac{x - \min x}{\max x - \min x} \tag{3}$$

Dengan I dan T sebagai skor konten ternormalisasi serta B sebagai WR ternormalisasi, tiga konfigurasi didefinisikan pada Persamaan (4). C1 memakai IndoBERT, C2 memakai TF-IDF, dan C3 memakai gabungan keduanya dengan bobot seimbang (0,5:0,5).

$$\begin{aligned} Skor(C1) &= 0{,}7 \cdot I + 0{,}3 \cdot B \\ Skor(C2) &= 0{,}7 \cdot T + 0{,}3 \cdot B \\ Skor(C3) &= 0{,}7 \cdot (0{,}5 \cdot I + 0{,}5 \cdot T) + 0{,}3 \cdot B \end{aligned} \tag{4}$$

Semua konfigurasi memakai bobot konten–rating 0,7:0,3, himpunan kandidat yang sama, dan pengurutan menurun menurut skor akhir. Bobot konten–rating 0,7:0,3 dan bobot IndoBERT–TF-IDF 0,5:0,5 ditetapkan sebagai pengaturan awal oleh penulis, tanpa penyetelan pada data validasi dan tanpa analisis sensitivitas bobot.

3.5. Kueri Uji

Berkas kueri versi 2.0 memuat 60 kueri berbahasa Indonesia dalam empat skenario yang masing-masing berisi 15 kueri: tanpa konteks, musim saja, kategori saja, serta musim dan kategori. Secara keseluruhan, 30 kueri tidak memiliki konteks musim, 15 berkonteks Kemarau, dan 15 berkonteks Penghujan. Tabel 2 memuat contoh kueri.

Seluruh kueri disusun secara manual oleh para penulis, bukan diambil dari log pencarian pengguna maupun studi lapangan. Konteks musim dan kategori setiap kueri dicatat sebagai kolom eksplisit pada berkas kueri, bukan diekstraksi dari teks. Kueri berkonteks kategori mencakup 14 kategori wisata: pantai 4 kueri dan 13 kategori lain masing-masing 2 kueri. Karena disusun oleh penulis sendiri, kueri berpotensi mencerminkan pengetahuan penulis tentang isi dataset dan variasi ungkapan yang terbatas, sehingga distribusinya tidak diasumsikan mewakili kebutuhan wisatawan nyata. Validasi eksternal terhadap kueri tidak dilakukan.

Tabel 2. Contoh kueri uji dan konteksnya.

ID	Teks kueri	Musim / kategori
Q001	Saya ingin mencari tempat wisata yang menarik untuk dikunjungi saat liburan.	Tidak ada / tidak ada
Q024	Saya ingin berwisata pada musim penghujan. Destinasi mana yang tetap direkomendasikan?	Penghujan / tidak ada
Q031	Saya ingin mengunjungi destinasi wisata pantai dan menikmati suasana pesisir.	Tidak ada / pantai
Q060	Saya ingin mengunjungi pantai saat musim penghujan.	Penghujan / pantai

3.6. Penilaian Relevansi

Pool penilaian adalah gabungan kandidat top-20 dari C1, C2, dan C3 dengan duplikat dihapus berdasarkan `query_id` dan `destination_id`. Hasilnya 1.467 pasangan, 2–44 pasangan per kueri (rata-rata 24,45), mencakup 203 destinasi. Proses anotasi relevansi dilakukan menggunakan model bahasa besar (*Large Language Model*/LLM) dengan bantuan ChatGPT untuk memberikan penilaian terhadap kesesuaian setiap pasangan query dan destinasi wisata. Proses anotasi dilaksanakan pada 9 November 2026. Penilaian menggunakan skala relevansi bertingkat 0–3, dengan label 0 menunjukkan destinasi tidak relevan, label 1 menunjukkan relevansi topik tetapi tidak sesuai konteks, label 2 menunjukkan relevansi sebagian, dan label 3 menunjukkan destinasi sangat relevan terhadap kebutuhan query. Instruksi anotasi dirancang dengan menempatkan kesesuaian karakteristik destinasi terhadap kebutuhan query sebagai dasar utama penilaian, sedangkan kondisi fasilitas dan kualitas pengalaman pengunjung digunakan sebagai bukti pendukung, bukan sebagai penentu utama. Informasi yang diberikan kepada model meliputi teks query, nama destinasi, kategori wisata, rekomendasi musim, serta teks ulasan pengunjung yang tersedia pada dataset. Rating dan jumlah ulasan digunakan sebagai informasi pendukung apabila diperlukan. Anotasi dilakukan berdasarkan rubrik penilaian yang telah ditentukan untuk menjaga konsistensi pemberian label. Karena proses penilaian menggunakan bantuan LLM dan belum melalui verifikasi independen oleh penilai manusia, label yang dihasilkan diperlakukan sebagai label relevansi hasil anotasi berbantuan LLM, bukan sebagai *ground truth* yang telah tervalidasi secara manusia. Karena tidak ada penilai manusia, label ini disebut penilaian relevansi otomatis, bukan *ground truth* terverifikasi manusia. Rubrik label disajikan pada Tabel 3.

Tabel 3. Rubrik label relevansi.

Label	Kategori	Definisi	Relevan (ketat)	Relevan (longgar)
0	Tidak relevan	Destinasi tidak sesuai dengan kebutuhan atau maksud kueri.	Tidak	Tidak
1	Relevan topik, tidak sesuai konteks	Sesuai secara umum, tetapi bertentangan dengan konteks musim atau kategori yang diminta.	Tidak	Tidak
2	Relevan sebagian	Memenuhi sebagian kebutuhan, tetapi belum kuat atau lengkap.	Tidak	Ya
3	Sangat relevan	Sangat sesuai dengan kebutuhan dan seluruh konteks kueri.	Ya	Ya

Penelitian ini melaporkan dua definisi relevansi biner. Definisi ketat menganggap hanya label 3 relevan (`is_relevant = int(relevance_label == 3)`), sedangkan definisi longgar menganggap label ≥ 2 relevan. Ekspor pertama memuat `is_relevant = 1` untuk seluruh pasangan, termasuk tiga pasangan berlabel 2, sehingga definisi longgar identik dengan ekspor tersebut. Definisi ketat ditetapkan setelah ekspor pertama dan bukan prosedur yang dipraregistrasikan. Label asli tidak diubah; NDCG memakai label bertingkat pada kedua definisi.

3.7. Metrik dan Analisis Statistik

Metrik dihitung pada K = 5, 10, dan 20 sebagai rata-rata makro atas 60 kueri. Dengan Rel_q himpunan destinasi relevan pada *pool* kueri q, π_q(i) destinasi pada peringkat i, dan rel_q(i) label destinasi tersebut, metrik didefinisikan pada Persamaan (5)–(7).

$$\text{Recall@K} = \frac{|\{i \leq K : \pi_q(i) \in Rel_q\}|}{|Rel_q|} \tag{5}$$

$$\text{MRR@K} = \frac{1}{\min\{i \leq K : \pi_q(i) \in Rel_q\}} \tag{6}$$

$$\text{NDCG@K} = \frac{DCG@K}{IDCG@K}$$

$$\text{DCG@K} = \sum_{i=1}^{K} \frac{2^{rel_q(i)} - 1}{\log_2(i+1)} \tag{7}$$

Pada Persamaan (6), nilai MRR@K adalah nol bila tidak ada destinasi relevan pada top-K. Destinasi tanpa label bergain nol. Selisih C3−C1 dan C3−C2 pada K = 10 diestimasi dengan interval persentil *bootstrap* berpasangan atas kueri (Efron, 1979; 10.000 pengambilan ulang, *seed* 42). Interval ini bersifat deskriptif pada himpunan kueri tetap. Seluruh 60 kueri bernilai valid untuk setiap konfigurasi, K, dan metrik, tanpa NaN. Lingkungan eksperimen, validasi konsistensi implementasi, dan batas replikasi dirinci pada Lampiran A.

4. Hasil dan Pembahasan

4.1. Kinerja Utama dengan Definisi Ketat (Label 3)

Ruang kandidat bergantung pada konteks: 207 destinasi tanpa konteks atau dengan Kemarau saja, 113 untuk Penghujan, 47 untuk kategori pantai, dan 17 untuk irisan pantai dan Penghujan. Tabel 4 memuat hasil utama. C1 memiliki rata-rata Recall, MRR, dan NDCG tertinggi pada ketiga nilai K, dengan selisih yang kecil. C3 tidak melampaui C1. Terhadap C2, C3 memiliki Recall dan MRR yang sama pada K = 10 dan 20, dengan selisih NDCG yang sangat kecil. Hasil ini tidak mendukung klaim bahwa fusi meningkatkan relevansi dibanding IndoBERT pada protokol ini.

Tabel 4. Kinerja konfigurasi dengan relevansi biner hanya label 3 (60 kueri valid per baris).

Konfigurasi	K	Recall@K	MRR@K	NDCG@K
C1	5	0,3197	1,0000	1,0000
C1	10	0,5277	1,0000	0,9994
C1	20	0,7600	1,0000	0,9993
C2	5	0,3186	0,9917	0,9952
C2	10	0,5266	0,9917	0,9961
C2	20	0,7595	0,9917	0,9975
C3	5	0,3180	0,9917	0,9941
C3	10	0,5266	0,9917	0,9962
C3	20	0,7595	0,9917	0,9975

C1 = IndoBERT + rating Bayesian; C2 = TF-IDF + rating Bayesian; C3 = fusi IndoBERT dan TF-IDF + rating Bayesian. NDCG memakai label bertingkat.

4.2. Sensitivitas terhadap Definisi Relevansi

Pada definisi longgar (label ≥ 2) ketiga konfigurasi memiliki MRR@10 sebesar 1,0000 dan Recall@10 sebesar 0,5277. Pada definisi ketat, MRR C2 dan C3 turun menjadi 0,9917 karena destinasi peringkat pertama pada Q001 berlabel 2. Recall juga berubah karena pembilang dan jumlah destinasi relevan acuan berubah bersamaan (Tabel 5). Selisih ini merupakan akibat definisi relevansi, bukan peningkatan atau penurunan model.

Tabel 5. Sensitivitas definisi relevansi pada K = 10.

Konfigurasi	Recall (longgar)	Recall (ketat)	MRR (longgar)	MRR (ketat)
C1	0,5277	0,5277	1,0000	1,0000
C2	0,5277	0,5266	1,0000	0,9917
C3	0,5277	0,5266	1,0000	0,9917

NDCG tidak berubah antardefinisi karena label bertingkat dipertahankan.

4.3. Hasil per Skenario

Pada K = 10, skenario kategori saja dan musim−kategori menghasilkan Recall 0,7321 dan 0,8117 untuk ketiga konfigurasi, sedangkan skenario musim saja menghasilkan 0,2898; MRR dan NDCG pada ketiganya sama dengan 1,0000. Pada skenario tanpa konteks, Recall C1 sebesar 0,2770 dan C2/C3 sebesar 0,2727, dengan MRR 1,0000 untuk C1 dan 0,9667 untuk C2/C3. Filter Kemarau menerima kedua label musim sehingga tidak mengurangi kandidat; dari 60 kueri, filter musim hanya menyaring pada 15 kueri Penghujan. Nilai antarskenario tidak mengukur efek kausal filter karena kueri dan ukuran kandidatnya berbeda.

4.4. Analisis Kasus: Q001

Seluruh perbedaan metrik antarkonfigurasi muncul pada Q001, permintaan umum untuk wisata menarik saat liburan. Tiga pasangan berlabel 2 (Bukit Kehi, Air Terjun Umbulan, dan Simpang Lima) semuanya berasal dari Q001. Seluruh pasangan pada 59 kueri lain berlabel 3. Pada Tabel 6, peringkat pertama C2 dan C3 berlabel 2 sehingga *reciprocal rank* Q001 bernilai 0,5, sedangkan C1 bernilai 1.

Tabel 6. Tiga peringkat awal Q001 (label relevansi pada tanda kurung).

Peringkat	C1	C2	C3
1	Air Terjun Tretes (3)	Bukit Kehi (2)	Bukit Kehi (2)
2	Taman Nasional Alas Purwo (3)	Pulau Bawean (3)	Air Terjun Tretes (3)
3	Pahlawan Street Center (3)	Simpang Lima (2)	Pahlawan Street Center (3)

4.5. Daya Pembeda Evaluasi

Pada K = 10, selisih rata-rata NDCG C3−C1 adalah −0,0032 (interval *bootstrap* 95% [−0,0095; 0,0000]) dan C3−C2 adalah 0,0001 ([0,0000; 0,0002]). Selisih Recall C3−C1 adalah −0,0011 ([−0,0032; 0,0000]) dan C3−C2 sama dengan nol. Selisih MRR C3−C1 adalah −0,0083 ([−0,0250; 0,0000]). Karena seluruh selisih bukan-nol berasal dari satu kueri, batas atas interval hampir selalu tepat nol; interval ini hanya mencerminkan seberapa sering Q001 tersampel, bukan kestabilan keunggulan pada beragam kebutuhan. Penelitian ini karena itu tidak menarik kesimpulan inferensial tentang keunggulan konfigurasi.

Penilaian relevansi sangat terkonsentrasi: 1.464 dari 1.467 pasangan (99,80%) berlabel 3, tiga (0,20%) berlabel 2, dan tidak ada label 0 atau 1. Dua sifat rancangan memperparah kejenuhan ini. Pertama, *pool* dibentuk setelah filter musim dan kategori sehingga konflik konteks, yang akan mendapat label 1, hampir tidak mungkin muncul; rubrik dan filter menilai hal yang sama. Kedua, bila hampir semua pasangan dalam *pool* relevan, Recall@K mendekati K dibagi ukuran *pool*, sehingga perbedaan Recall antarskenario (0,2898 pada musim saja dibanding 0,8117 pada musim−kategori) terutama mencerminkan ukuran *pool*. Recall yang dilaporkan adalah recall terhadap destinasi relevan di dalam *pool*, bukan di seluruh koleksi. Karena *pool* terdiri atas top-20 ketiga konfigurasi dan K tidak melebihi 20, semua destinasi pada top-K telah dinilai; pada K > 20 destinasi yang belum dinilai akan diperlakukan bergain nol.

5. Pembahasan dan Keterbatasan

5.1. Pembahasan

Fusi IndoBERT−TF-IDF tidak memberi manfaat terukur dibanding IndoBERT pada koleksi ini. Hasil ini tidak berarti fusi tidak berguna: evaluasi yang tersedia tidak mampu memisahkan konfigurasi. Hampir semua pasangan dalam *pool* berlabel 3, sehingga ketiga konfigurasi tampak hampir sempurna pada MRR dan NDCG, dan satu-satunya kueri yang membedakan (Q001) adalah kueri paling umum dan paling tidak spesifik. Pola ini sejalan dengan peringatan bahwa evaluasi berbasis *pool* menguntungkan sistem pembentuk *pool* (Zobel, 1998) dan bahwa ukuran metrik rekomendasi dipengaruhi distribusi relevansi dan popularitas (Mena-Maldonado et al., 2021).

Penilai otomatis yang belum divalidasi menambah ketidakpastian. Kajian tentang penilai LLM melaporkan bias posisi, panjang, dan preferensi terhadap keluaran model sendiri (Zheng et al., 2023; Nadăş, 2026). Tanpa kesepakatan dengan penilai manusia, validitas label sebagai ukuran kebutuhan

semantik belum dapat dinilai, dan label tidak diubah untuk memperoleh sebaran yang lebih seimbang. Selain itu, ketiga konfigurasi sama-sama memakai rating dan filter, sehingga perbandingan ini tidak memisahkan sumbangan rating, konteks, dan representasi teks.

5.2. Keterbatasan

1. **Penilaian relevansi.** Penilai tunggal, otomatis, tanpa validasi manusia atau kesepakatan antarpenilai; 99,80% label bernilai 3.
2. **Sirkularitas filter–rubrik.** Filter musim dan kategori ikut menentukan kandidat sekaligus relevansi, sehingga kecocokan semantik ulasan sulit dipisahkan dari kepatuhan filter.
3. **Filter Kemarau.** Filter ini tidak menyaring apa pun, sehingga pengaruh konteks musim hanya teruji pada kueri Penghujan.
4. **Normalisasi tidak setara.** WR dinormalisasi pada seluruh destinasi, sedangkan skor konten dinormalisasi pada kandidat per kueri; bobot efektif 0,7:0,3 dapat berubah antarskenario.
5. **Praproses kueri.** Ulasan dibersihkan tetapi kueri tidak, yang dapat memengaruhi TF-IDF pada kueri berbentuk kalimat lengkap.
6. **Representasi.** IndoBERT tanpa *fine-tuning*, panjang maksimum 128 token yang memotong ulasan panjang, serta rata-rata ulasan per destinasi yang jumlahnya berkisar 7–1.331 (Reimers & Gurevych, 2019).
7. **Data.** Koleksi tunggal; 631 baris duplikat penuh dan 2.842 pengulangan pasangan ID–teks dipertahankan; artefak encoding dapat lolos pembersihan; sumber, izin, dan lokasi data belum diverifikasi.
8. **Rancangan eksperimen.** Bobot tetap tanpa pemisahan kueri validasi; tidak ada *baseline* (rating saja, popularitas, BM25) maupun ablasi filter; kueri disusun tim penulis dan bukan berasal dari pengguna.

5.3. Pekerjaan Lanjutan

Prioritas utama adalah memperkuat bukti penilaian, bukan menambah model: (a) penilai manusia pada sampel pasangan (termasuk seluruh Q001) dengan kesepakatan Cohen's κ atau Krippendorff's α terhadap penilai LLM; (b) destinasi sulit (*hard negatives*) dari luar *pool* agar label 0–2 benar-benar muncul; (c) lebih dari satu penilai LLM dari keluarga model berbeda; (d) evaluasi pada kueri tanpa filter atau penilaian yang tidak memberi kredit atas musim dan kategori; (e) *baseline* dan ablasi, analisis sensitivitas bobot pada kueri validasi, dan pembandingan dengan model *sentence embedding* (Reimers & Gurevych, 2019); serta (f) analisis dengan dan tanpa deduplikasi ulasan.

6. Kesimpulan

Pada koleksi 207 destinasi dan 60 kueri, fusi skor IndoBERT–TF-IDF dengan rating Bayesian dan filter musim tidak meningkatkan relevansi dibanding IndoBERT (RQ1 dan RQ2): dengan relevansi ketat, MRR@10 C1 sebesar 1,0000 dan C2/C3 sebesar 0,9917, dengan NDCG@10 ketiganya di atas 0,996. Perubahan definisi relevansi dari longgar ke ketat hanya memengaruhi Q001. Penilaian relevansi otomatis yang tersedia belum cukup membedakan konfigurasi (RQ3), karena 99,80% label bernilai 3,

seluruh selisih berasal dari satu kueri, dan Recall sangat dipengaruhi ukuran *pool*. Kontribusi yang dapat dipertahankan adalah perbandingan terkendali dan protokol evaluasi yang dapat ditelusuri; klaim keunggulan metode memerlukan penilaian yang lebih sulit, validasi manusia, dan eksperimen pembanding terkontrol.

7. Deklarasi Penggunaan AI

ChatGPT membantu penyusunan draf, penyelarasan metode, audit komputasional, dan penyuntingan bahasa. Penulis menyatakan bahwa penilaian relevansi dihasilkan secara otomatis menggunakan GPT-6. Konfigurasi, instruksi, dan log penilaian masih perlu dilengkapi, terpisah dari penggunaan AI untuk penulisan. Penulis bertanggung jawab meninjau isi dan menyetujui naskah sebelum pengajuan; peninjauan akhir belum dinyatakan selesai dalam draf ini.

8. Pernyataan Kontribusi Penulis CRediT

Malik Hariyanto: Konseptualisasi, Metodologi, Administrasi Proyek, Penulisan—Draf Awal, dan Penulisan—Tinjauan dan Penyuntingan. Muhammad Rifqi Razzan Pratama: Kurasi Data, Investigasi, Sumber Daya, dan Penulisan—Tinjauan dan Penyuntingan. Muhammad Iqbal Faza: Perangkat Lunak, Analisis Formal, Validasi, dan Penulisan—Tinjauan dan Penyuntingan. Yahya Ahmad: Perangkat Lunak, Visualisasi, Validasi, dan Penulisan—Draf Awal.

9. Pernyataan Konflik Kepentingan

Penulis menyatakan bahwa tidak terdapat konflik kepentingan yang dapat memengaruhi penelitian, penulisan, atau publikasi artikel ini.

10. Ucapan Terima Kasih

Penulis mengucapkan terima kasih kepada Dr. Imamah, S.Kom., M.Kom., selaku dosen pembimbing, atas bimbingan, arahan, dan masukan yang diberikan selama pelaksanaan penelitian dan penyusunan naskah ini.

11. Ketersediaan Data

Data yang digunakan dalam penelitian ini tidak dapat dibagikan kepada publik karena berupa kumpulan ulasan pengguna yang diambil dari Google Maps. Ulasan tersebut merupakan konten buatan pengguna yang hak pemakaian dan distribusinya berada pada pengulas dan penyedia platform, sehingga penyebarluasan ulang tunduk pada ketentuan layanan platform tersebut. Teks ulasan juga dapat memuat informasi pribadi yang tidak sengaja dituliskan pengulas. Berkas turunan yang tidak memuat teks ulasan, yaitu daftar kueri uji, penilaian relevansi (qrels), dan berkas peringkat, tersedia dari penulis korespondensi berdasarkan permintaan yang wajar.

12. Pendanaan

Penelitian ini tidak menerima pendanaan khusus dari lembaga pemerintah, komersial, atau organisasi nirlaba.

13. Persetujuan Etik

Penelitian ini menggunakan data sekunder berupa ulasan publik yang diperoleh dari Google Maps. Penelitian tidak melibatkan interaksi langsung dengan manusia, intervensi, maupun pengumpulan data dari partisipan. Dataset tidak memuat kolom nama atau akun pengulas, dan analisis dilakukan pada tingkat destinasi, bukan individu. Penelitian ini tidak menjalani tinjauan komite etik karena tidak melibatkan subjek manusia secara langsung.

14. Daftar Pustaka

Almomani, A., Saavedra, P., Barreiro, P., Durán, R., Crujeiras, R., Loureiro, M., & Sánchez, E. (2022). Application of choice models in tourism recommender systems. Expert Systems, 40(3), e13177. https://doi.org/10.1111/exsy.13177

Arif, Y. M., Nurhayati, H., Nugroho, S. M. S., & Hariadi, M. (2022). Destinations ratings based multi-criteria recommender system for Indonesian halal tourism game. International Journal of Intelligent Engineering and Systems, 15(1). https://doi.org/10.22266/ijies2022.0228.26

Banerjee, A., Banik, P., & Wörndl, W. (2023). A review on individual and multistakeholder fairness in tourism recommender systems. Frontiers in Big Data, 6, 1168692. https://doi.org/10.3389/fdata.2023.1168692

Banerjee, A., Mahmudov, T., Adler, E., Aisyah, F. N., & Wörndl, W. (2025). Modeling sustainable city trips: integrating CO_2e emissions, popularity, and seasonality into tourism recommender systems. Information Technology & Tourism, 27(1), 189-226. https://doi.org/10.1007/s40558-024-00303-1

Chalkiadakis, G., Ziogas, I., Koutsmanis, M., Streviniotis, E., Panagiotakis, C., & Papadakis, H. (2023). A Novel Hybrid Recommender System for the Tourism Domain. Algorithms, 16(4), 215. https://doi.org/10.3390/a16040215

Cormack, G. V., Clarke, C. L. A., & Buettcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (pp. 758–759). ACM.

Craswell, N. (2009). Mean reciprocal rank. In L. Liu & M. T. Özsu (Eds.), Encyclopedia of database systems (p. 1703). Springer.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT 2019 (pp. 4171–4186). Association for Computational Linguistics.

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 7(1), 1–26.

Gamidullaeva, L., Finogeev, A., Kataev, M., & Bulysheva, L. (2023). A Design Concept for a Tourism Recommender System for Regional Development. Algorithms, 16(1), 58. https://doi.org/10.3390/a16010058

Henriques, R., & Pinto, L. (2023). A novel evaluation framework for recommender systems in big data environments. Expert Systems with Applications, 231, 120659. https://doi.org/10.1016/j.eswa.2023.120659

Huda, C., Heryadi, Y., Lukas, & Budiharto, W. (2024). Smart Tourism Recommender System Modeling Based on Hybrid Technique and Content Boosted Collaborative Filtering. IEEE Access, 12, 131794-131808. https://doi.org/10.1109/access.2024.3450882

Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems, 20(4), 422–446.

Li, J., Xue, H., Tang, Q., Wang, H., & Gao, T. (2024). SABTR: semantic analysis-based tourism recommendation. Frontiers in Physics, 12, 1491365. https://doi.org/10.3389/fphy.2024.1491365

Mena-Maldonado, E., Cañamares, R., Castells, P., Ren, Y., & Sanderson, M. (2021). Popularity Bias in False-positive Metrics for Recommender Systems Evaluation. ACM Transactions on Information Systems, 39(3), 1-43. https://doi.org/10.1145/3452740

Nadăş, M. D. (2026). Large language models as judges: recent advances in LLM-based evaluation, critique, preference modeling, and feedback for text and code. Artificial Intelligence Review, . https://doi.org/10.1007/s10462-026-11652-0

Piliponyte, G., Massimo, D., & Ricci, F. (2024). Simulation of recommender systems driven tourism promotion campaigns. Information Technology & Tourism, 26(3), 407-448. https://doi.org/10.1007/s40558-024-00283-2

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Proceedings of EMNLP-IJCNLP 2019 (pp. 3982–3992). Association for Computational Linguistics.

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523.

Sharma, S., Rana, V., & Kumar, V. (2021). Deep learning based semantic personalized recommendation system. International Journal of Information Management Data Insights, 1(2), 100028. https://doi.org/10.1016/j.jjimei.2021.100028

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. In Proceedings of AACL-IJCNLP 2020 (pp. 843–857). Association for Computational Linguistics.

Yoon, J., & Choi, C. (2023). Real-Time Context-Aware Recommendation System for Tourism. Sensors, 23(7), 3679. https://doi.org/10.3390/s23073679

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. Advances in Neural Information Processing Systems, 36.

Zheng, Y. (2022). DeepCARSKit: A deep learning based context-aware recommendation library. Software Impacts, 13, 100292. https://doi.org/10.1016/j.simpa.2022.100292

Zobel, J. (1998). How reliable are the results of large-scale information retrieval experiments? In Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (pp. 307–314). ACM.